Evaluación de modelos de visión computacional para detectar ocultamiento de mercancía

Maestría en Inteligencia Artificial Aplicada

Jesús Alberto Jiménez Ramos Nélida Silva Cabrera José Luis Tinajero Guerrero
Asesor: Dr. Guillermo Mota Medina · Noviembre 2026

Contexto de negocio y problema

BNext desarrolla soluciones de videoanalítica para el sector minorista. La revisión manual de grabaciones requiere tiempo y recursos, lo que puede dificultar la identificación oportuna de eventos de interés.

Problema: determinar si es posible identificar automáticamente, mediante modelos de visión computacional, la acción de ocultar mercancía en una secuencia de video.

Objetivo: evaluar modelos capaces de distinguir eventos de ocultamiento de comportamientos normales y generar alertas para revisión humana.

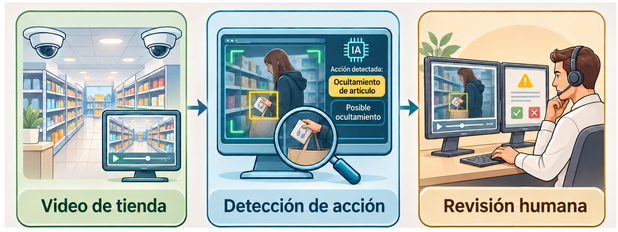


Figura 1. Flujo conceptual (interfaz simulada).

Alcance: detectar ocultamiento no equivale a confirmar un hurto. La revisión y las decisiones posteriores corresponden al personal responsable.

Datos y preparación

Fuentes: CCTV_YOLO, DCSASS, MNNIT y SINTÉTICO.

Dataset v2: 974 clips elegibles en 63 grupos experimentales; se excluyeron 11 clips ambiguos de prueba.

Control: clips relacionados en una misma partición; 16 frames RGB por clip.

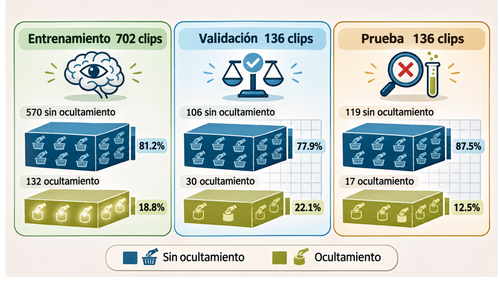


Figura 2. Distribución de clases por partición (dataset v2).

Metodología y modelos

Se siguió CRISP-ML(Q). Se evaluaron cinco arquitecturas RGB: R3D-18, MC3-18, R(2+1)D-18, S3D y MViT-V2-S, con pesos Kinetics-400; STG-NF se evaluó por separado con poses de RetailS.

Modelo elegido: R(2+1)D-18/H5 (fine-tuning de layer4 y clasificador); modelo y umbral se eligieron con validación. Test v2 excluye 11 casos ambiguos identificados al revisar errores del baseline; no constituye una evaluación confirmatoria independiente.

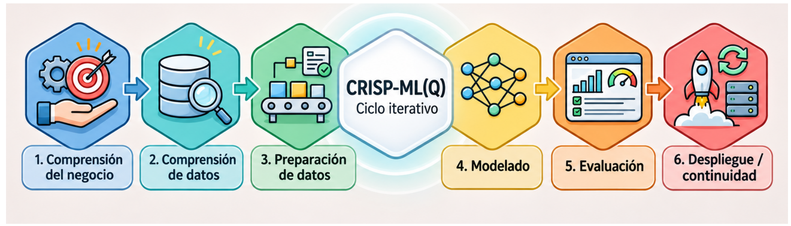


Figura 3. Etapas CRISP-ML(Q); despliegue propuesto, no implementado.

Resultados y validación

En **test v2** (136 clips: 17 con ocultamiento, 119 sin ocultamiento), R(2+1)D-18/H5 alcanzó un AP puntual superior al baseline R3D-18. Las probabilidades se calcularon con `softmax` FP32.

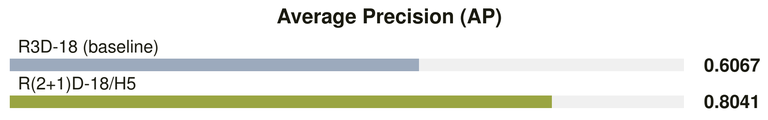


Figura 4. AP en test v2 (Equipo 41, 2026).

Precisión	Recall	Especificidad	F1
78.6 %	64.7 %	97.5 %	0.7097

Umbral: 0.9969, fijado en validación. En prueba hubo **3 falsos positivos** y **6 falsos negativos**.

Matriz de confusión: R(2+1)D-18/H5

	Pred. normal	Pred. alerta
Real normal	**116** TN	**3** FP
Real ocultamiento	**6** FN	**11** TP

Figura 5. Matriz de confusión en test v2.

Incertidumbre: ΔAP puntual $= +0.1974$; IC 95 % por bootstrap pareado de grupos: $[-0.1143,\ 0.2280]$. Incluye cero, por lo que no demuestra superioridad estadística robusta.

Conclusiones clave

1. Viabilidad experimental. R(2+1)D-18/H5 mostró capacidad para identificar patrones de ocultamiento en los videos evaluados. Los resultados justifican continuar hacia una demostración funcional.

2. Compromiso entre tipos de error. Frente al baseline, el modelo final redujo los falsos positivos de 11 a 3, pero aumentó los falsos negativos de 2 a 6. El umbral operativo deberá definirse con BNext.

3. Generalización pendiente. La ausencia de videos operativos reales, las limitaciones del dataset y la incertidumbre estadística impiden recomendar todavía su implementación en tiendas.

Comparación de errores en test v2

Falsos positivos	Falsos negativos
11 → 3	**2 → 6**
Menos alertas incorrectas	Más eventos omitidos

Figura 6. Comparación sobre 136 clips de test v2; cada modelo utiliza su umbral fijado en validación.

Trabajo futuro



1. Validar datos reales
Evaluar videos autorizados: ángulos, iluminación y oclusiones; medir desempeño por escenario y tipo de ocultamiento.

2. Definir alertas
Acordar tolerancia a falsas alertas, eventos omitidos y carga de revisión. Ajustar el umbral con validación representativa.

3. Evaluar viabilidad
Demostrar alertas en videos grabados; medir latencia, memoria y cómputo. Evaluar documentalmente opciones de hardware edge.

Figura 7. Continuidad propuesta para BNext; no implementada.

Referencias

- Visengeriyeva, L., Kammer, A., Bär, I., Kniesz, A., & Plöd, M. (2023). *CRISP-ML(Q): The ML Lifecycle Process*. MLOps. ml-ops.org/content/crisp-ml.
- Tran, D., Wang, H., Torresani, L., Ray, J., LeCun, Y., & Paluri, M. (2018). *A Closer Look at Spatiotemporal Convolutions for Action Recognition*. CVPR, 6450–6459. doi:10.1109/CVPR.2018.00675.
- Hirschorn, O., & Avidan, S. (2023). *Normalizing Flows for Human Pose Anomaly Detection*. ICCV, 13545–13554. doi:10.1109/ICCV51070.2023.01246.
- Ansari, M. A., & Singh, D. K. (2023). *Shoplifting Dataset (2022)* (V1) [Conjunto de datos]. Mendeley Data. doi:10.17632/r3yjf35hzr.1.

Declaración de uso de inteligencia artificial. Se utilizó OpenAI ChatGPT (GPT-6, 2026) como apoyo en la revisión de redacción, elaboración de diagramas e imagenes y generación y depuración de código LaTeX. Los datos, experimentos y resultados provienen del trabajo documentado por el Equipo 41. Los autores revisaron y validaron el contenido final.